

o1

2

熵和互信息量的基本性质

2. 熵和互信息量的基本性质

o2

- 离散随机变量
 - 一维随机变量 X ，取值离散
即 $X \in \{x_1, x_2, \dots, x_r\}$
 - N 维随机矢量 \mathbf{X} ，时间离散、取值离散
即 $\mathbf{X} = (X_1, X_2, \dots, X_N)$
 $X_i \in \{x_1, x_2, \dots, x_r\}$
 $i=1, 2, \dots, N$

目录

o3

- 熵的性质
- 互信息量的性质
- 条件熵及Fano不等式
- 复合观测的互信息量
- 数据处理定理
- 互信息量与信道输入概率分布的关系
- 互信息量与信道转移概率分布的关系
- 互信息量与信道输入符号相关性的关系
- 互信息量与信道记忆特性的关系

2.1 熵的性质

o4

定理2.1: 设离散随机变量 X 在定义域

$R = \{x_1, x_2, \dots, x_r\}$ 内取值,

则 $0 \leq H(X) \leq \log r$

$H(X) = 0$,

当且仅当对于某个 i , $p_i = 1$

$H(X) = \log r$,

当且仅当对于所有 i , $p_i = 1/r$

目录

o5

- 熵的性质
- 互信息量的性质
- 条件熵及Fano不等式
- 复合观测的互信息量
- 数据处理定理
- 互信息量与信道输入概率分布的关系
- 互信息量与信道转移概率分布的关系
- 互信息量与信道输入符号相关性的关系
- 互信息量与信道记忆特性的关系

2.2 互信息量的性质

o6

定理2.2: 对于任意一对随机变量 X 和 Y ,

$$I(X; Y) \geq 0$$

当且仅当 X, Y 相互独立时,

$$I(X; Y) = 0$$

目录

o7

- 熵的性质
- 互信息量的性质
- 条件熵及Fano不等式
- 复合观测的互信息量
- 数据处理定理
- 互信息量与信道输入概率分布的关系
- 互信息量与信道转移概率分布的关系
- 互信息量与信道输入符号相关性的关系
- 互信息量与信道记忆特性的关系

2.3 条件熵及Fano不等式

o8

定理2.3: 设 X, Y, Z 是离散随机变量,
对于每个 z , 定义

$$A(z) = \sum_{x,y} p(y)p(z/x, y)$$

则 $H(X/Y) \leq H(Z) + E[\log A(z)]$

2.3 条件熵及Fano不等式

09

证明:

$$H(X/Y) = E\left[\log \frac{1}{p(x/y)}\right] = \sum_{x,y,z} p(x,y,z) \log \frac{1}{p(x/y)}$$

$$= \sum_z p(z) \sum_{x,y} \frac{p(x,y,z)}{p(z)} \log \frac{1}{p(x/y)}$$

$$\leq \sum_z p(z) \log \left[\frac{1}{p(z)} \cdot \sum_{x,y} \frac{p(x,y,z)}{p(x/y)} \right]$$

$$A(z) = \sum_{x,y} p(y) p(z/x, y)$$

$$= \sum_z p(z) \log \frac{1}{p(z)} + \sum_z p(z) \log \sum_{x,y} \frac{p(x,y,z)}{p(x/y)}$$

(其中 $p(x,y,z)/p(x/y) = p(x,y,z)p(y)/p(x,y) = p(y)p(z/x,y)$)

$$= H(z) + E[\log A(z)]$$

证毕!

2.3 条件熵及Fano不等式



例2.1：设 X 和 Y 是两个离散随机变量，
定义其和为 $Z=X+Y$ （普通加法），
若 X 和 Y 相互独立，
求证： $H(X) \leq H(Z)$

2.3 条件熵及Fano不等式



证明1：设 X 取值于 (x_1, x_2, \dots, x_m) .

Y 取值于 (y_1, y_2, \dots, y_n) .

对于 Z 的任一取值 z_i

$$\text{设 } z_i = x_{i1} + y_{i1} = x_{i2} + y_{i2} = \dots = x_{ik} + y_{ik}$$

$$\text{定义 } A(z) = \sum_{x,y} p(y) p(z/x, y)$$

$$\text{则 } A(z = z_i) = \sum_y p(y) \sum_x p(z_i / x, y) = \sum_{l=1}^k p(y_{il}) \leq 1$$

因此 $A(z) \leq 1$

2.3 条件熵及Fano不等式



证明1

(续) : 利用定理2.3, 有

$$H(X/Y) \leq H(Z) + E[\log A(z)] \leq H(Z)$$

又因为X和Y相互独立,

$$\text{即 } I(X; Y) = 0$$

$$\text{则 } H(X/Y) = H(X) - I(X; Y) = H(X)$$

$$\text{因此 } H(X) \leq H(Z)$$

2.3 条件熵及Fano不等式



证明2: 因为 $Z=X+Y$

所以对于任意 y_i 和 k ,

有 $p(z_k/y_i)=p(x_k)$

因此 $H(Z/Y=y_i)=H(X)$

$$H(Z/Y)=\sum_{y_i} p(y_i)H(Z/Y=y_i)=H(X)$$

而 $H(Z)-H(Z/Y)=I(Z;Y)\geq 0$

因此 $H(Z) \geq H(Z/Y)=H(X)$

2.3 条件熵及Fano不等式



推论: (Fano Inequality)

设 X, Y 是随机变量,

取值于符号集 (x_1, x_2, \dots, x_r) .

定义 $P_e = P\{X \neq Y\}$.

则 $H(X/Y) \leq H(P_e) + P_e \log(r-1)$

2.3 条件熵及Fano不等式



证明：定义 $z = 0$, 若 $x = y$; $z = 1$, 若 $x \neq y$.

$$\text{则 } P_r(z = 0) = 1 - P_e, \quad P_r(z = 1) = P_e$$

$$H(Z) = H(P_e, 1 - P_e) = H(P_e)$$

$$\text{已知 } A(z) = \sum_{x,y} p(y) p(z / x, y)$$

$$\text{其中 } A(z = 0) = \sum_{x,y} p(y) p(x = y / x, y)$$

$$= \sum_y p(y) \left[\sum_x p(x = y / x, y) \right] = \sum_y p(y) = 1$$

$$A(z = 1) = \sum_{x,y} p(y) p(x \neq y / x, y)$$

$$= \sum_y p(y) \left[\sum_x p(x \neq y / x, y) \right] = \sum_y p(y) (r - 1) = r - 1$$

2.3 条件熵及Fano不等式



证明（续）：

根据定理2.3

$$H(X/Y) \leq H(Z) + E[\log A(z)]$$

$$\begin{aligned} \text{有 } H(X/Y) &\leq H(P_e) + P_e \log(r-1) + (1-P_e) \log 1 \\ &= H(P_e) + P_e \log(r-1) \end{aligned}$$

2.3 条件熵及Fano不等式



分析：

(1) $H(X/Y)$ 是 Y 已知后，仍需通过观测 X 才能获得的信息量；

(2) 观测 X 的一种方法是首先确定 $X=Y$ ：

如果 $X=Y$ ，则达到目的；

如果 $X \neq Y$ ，则 X 有 $r-1$ 种可能的取值。

(3) 检测 $X=Y$ 等同于观测 Z ，

而 $H(Z) = H(P_e)$

(4) 如果 $X \neq Y$ （概率为 P_e ）

保留的不确定量最多为 $\log(r-1)$

因此 $H(X/Y) \leq H(P_e) + P_e \log(r-1)$

目录



- 熵的性质
- 互信息量的性质
- 条件熵及Fano不等式
- 复合观测的互信息量
- 数据处理定理
- 互信息量与信道输入概率分布的关系
- 互信息量与信道转移概率分布的关系
- 互信息量与信道输入符号相关性的关系
- 互信息量与信道记忆特性的关系

2.4 复合观测的互信息量



定理2.4: $I(X, Y; Z) \geq I(Y; Z)$.

当且仅当 $p(z/x, y) = p(z/y)$ 时,
等式成立.

$I(X, Y; Z) \geq I(X; Z)$.

当且仅当 $p(z/x, y) = p(z/x)$ 时,
等式成立.

2.4 复合观测的互信息量



$$\begin{aligned}\text{证明: } I(Y;Z) - I(X,Y;Z) &= E\left[\log \frac{p(z/y)}{p(z)} - \log \frac{p(z/x,y)}{p(z)}\right] \\&= E\left[\log \frac{p(z/y)}{p(z/x,y)}\right] \\&= \sum_{x,y,z} p(x,y,z) \log \frac{p(z/y)}{p(z/x,y)} \\&\leq \log \sum_{x,y,z} p(x,y,z) \frac{p(z/y)}{p(x,y,z)/p(x,y)} \\&= \log \sum_{x,y,z} p(x,y) p(z/y) \\&= \log 1 = 0\end{aligned}$$

证毕!

目录




- 熵的性质
- 互信息量的性质
- 条件熵及Fano不等式
- 复合观测的互信息量
- 数据处理定理
- 互信息量与信道输入概率分布的关系
- 互信息量与信道转移概率分布的关系
- 互信息量与信道输入符号相关性的关系
- 互信息量与信道记忆特性的关系

2.5 数据处理定理



Markov信道链：



(X, Y, Z) 是Markov链 $\Rightarrow (Z, Y, X)$ 也是Markov链

$$\text{即 } p(z/x, y) = p(z/y) \Rightarrow p(x/y) = p(x/y, z)$$

2.5 数据处理定理



定理2.5: 设 (X, Y, Z) 是一个Markov链, 则有

$$I(X; Z) \leq \begin{cases} I(X; Y) \\ I(Y; Z) \end{cases}$$

2.5 数据处理定理



证明: 由定理2.4, 有 $I(X; Z) \leq I(X, Y; Z)$

因为 (X, Y, Z) 是 Markov 链, 有

$$I(X, Y; Z) = I(Y; Z)$$

所以 $I(X; Z) \leq I(Y; Z)$

又因为 (X, Y, Z) 是 Markov 链

$\Rightarrow (Z, Y, X)$ 也是 Markov 链

有 $I(Z, Y; X) = I(Y; X) = I(X; Y)$

而 $I(Z, Y; X) \geq I(Z; X) = I(X; Z)$

所以 $I(X; Z) \leq I(X; Y)$

2.5 数据处理定理





物理意义：数据处理**不能增加**信息！

例2.2: X_1, X_2, X_3 是独立随机变量,
因此 $(X_1, X_1+X_2, X_1+X_2+X_3)$ 是Markov 链
有 $I(X_1; X_1+X_2+X_3) \leq I(X_1; X_1+X_2)$

2.5 数据处理定理



例题2.3:



2.5 数据处理定理



例题2.2（续）：


$$I(X; Y) = 1 - H_2(p)$$

$$I(X; Z) = 1 - H_2[2p(1-p)]$$

2.5 数据处理定理



例题2.2（续）：



TRANSMITTER



The Comms. Research Group deep in thought

CHANNEL




Image Corrupted by Channel Noise (1.0 dB)

RECEIVER



After 1 Turbo Decoding Step



After 2 Iterations



After 10 Iterations

Turbo Decoding of a Bit-Map Image

Turbo Decoding is a powerful error correcting tool, that can be used to protect digital signals transmitted over radio channels. The term 'Turbo' refers to the iterative (repeated) processing of the received signal. Turbo codes tend to perform better than any other code at low signal-to-noise ratios (noisy signals). Here we can see a simulation of a digitised image being transmitted over a noisy radio channel.

目录




- 熵的性质
- 互信息量的性质
- 条件熵及Fano不等式
- 复合观测的信息量
- 数据处理定理
- 互信息量与信道输入概率分布的关系
- 互信息量与信道转移概率分布的关系
- 互信息量与信道输入符号相关性的关系
- 互信息量与信道记忆特性的关系

2.6 互信息量与信道输入概率分布的关系



定理2.6: $I(X; Y)$ 是信道输入概率分布 $p(x)$ 的
上凸函数.



说明: $p(x) = \alpha p_1(x) + \beta p_2(x)$. ($\alpha, \beta \geq 0$ $\alpha + \beta = 1$)

定理成立, 即 $\alpha I(X_1; Y_1) + \beta I(X_2; Y_2) \leq I(X; Y)$

2.6 互信息量与信道输入概率分布的关系



证明: $\alpha I(X_1; Y_1) + \beta I(X_2; Y_2) - I(X; Y)$

$$\begin{aligned} &= \sum_{x,y} \alpha p_1(x, y) \log \frac{p(y/x)}{p_1(y)} + \sum_{x,y} \beta p_2(x, y) \log \frac{p(y/x)}{p_2(y)} \\ &\quad - \sum_{x,y} [\alpha p_1(x, y) + \beta p_2(x, y)] \log \frac{p(y/x)}{p(y)} \\ &= \alpha \sum_{x,y} p_1(x, y) \log \frac{p(y)}{p_1(y)} + \beta \sum_{x,y} p_2(x, y) \log \frac{p(y)}{p_2(y)} \end{aligned}$$

2.6 互信息量与信道输入概率分布的关系



$$\begin{aligned}\text{证明: } & \leq \alpha \log \sum_{x,y} p_1(x,y) \frac{p(y)}{p_1(y)} + \beta \log \sum_{x,y} p_2(x,y) \frac{p(y)}{p_2(y)} \\ & = \alpha \log \sum_y \frac{p(y)}{p_1(y)} \sum_x p_1(x,y) + \beta \log \sum_y \frac{p(y)}{p_2(y)} \sum_x p_2(x,y) \\ & = \alpha \log \sum_y \frac{p(y)}{p_1(y)} p_1(y) + \beta \log \sum_y \frac{p(y)}{p_2(y)} p_2(y) \\ & = \alpha \log 1 + \beta \log 1 = 0\end{aligned}$$

证毕!

目录

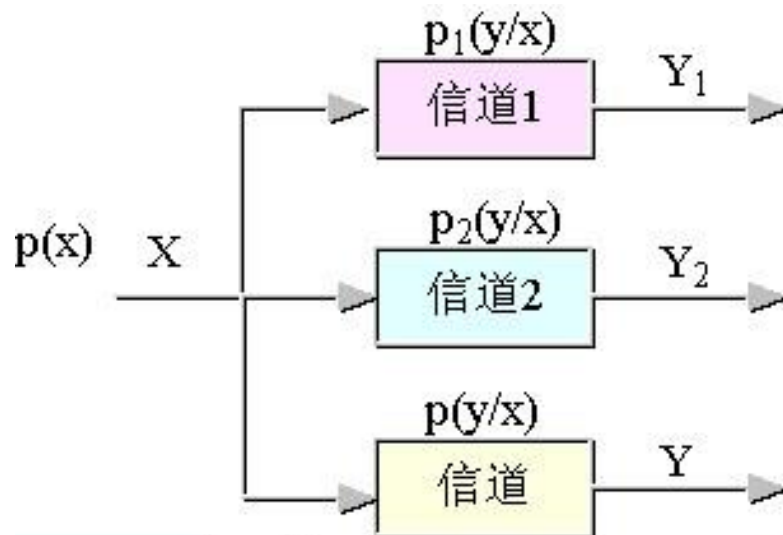


- 熵的性质
- 互信息量的性质
- 条件熵及Fano不等式
- 复合观测的互信息量
- 数据处理定理
- 互信息量与信道输入概率分布的关系
- 互信息量与信道转移概率分布的关系
- 互信息量与信道输入符号相关性的关系
- 互信息量与信道记忆特性的关系

2.7 互信息量与信道转移概率分布的关系



定理2.7: $I(X; Y)$ 是信道转移概率分布 $p(y/x)$ 的
下凹函数.



说明: $p(y/x) = \alpha p_1(y/x) + \beta p_2(y/x)$. ($\alpha, \beta \geq 0$ $\alpha + \beta = 1$)

定理成立, 即 $I(X; Y) \leq \alpha I(X; Y_1) + \beta I(X; Y_2)$

目录



- 熵的性质
- 互信息量的性质
- 条件熵及Fano不等式
- 复合观测的互信息量
- 数据处理定理
- 互信息量与信道输入概率分布的关系
- 互信息量与信道转移概率分布的关系
- 互信息量与信道输入符号相关性的关系
- 互信息量与信道记忆特性的关系

2.8 互信息量与信道输入符号相关性的关系



定理2.8：信道的输入是离散无记忆的

$$\begin{aligned}\text{即 } p(\mathbf{x}) &= p(x_1, x_2, \dots, x_N) \\ &= p(x_1)p(x_2)\cdots p(x_N) = \prod_{i=1}^N p(x_i)\end{aligned}$$

$$\text{则 } I(\mathbf{X}; \mathbf{Y}) \geq \sum_{i=1}^N I(X_i; Y_i)$$

2.8 互信息量与信道输入符号相关性的关系



证明:

$$I(\mathbf{X}; \mathbf{Y}) = E \left[\log \frac{p(\mathbf{x}/\mathbf{y})}{p(\mathbf{x})} \right]$$
$$= E \left[\log \frac{p(\mathbf{x}/\mathbf{y})}{p(x_1)p(x_2)\cdots p(x_N)} \right]$$
$$\sum_{i=1}^N I(X_i; Y_i) = \sum_{i=1}^N E \left[\log \frac{p(x_i / y_i)}{p(x_i)} \right]$$
$$= E \left[\log \frac{p(x_1 / y_1) \cdots p(x_N / y_N)}{p(x_1) \cdots p(x_N)} \right]$$

2.8 互信息量与信道输入符号相关性的关系



证明: $\sum_{i=1}^N I(X_i; Y_i) - I(\mathbf{X}; \mathbf{Y})$

$$= E \left[\log \frac{p(x_1 / y_1) \cdots p(x_N / y_N)}{p(\mathbf{x} / \mathbf{y})} \right]$$

$$\leq \log E \left[\frac{p(x_1 / y_1) \cdots p(x_N / y_N)}{p(\mathbf{x} / \mathbf{y})} \right]$$

$$= \log \left[\sum_{\mathbf{x}, \mathbf{y}} p(\mathbf{x} / \mathbf{y}) p(\mathbf{y}) \frac{p(x_1 / y_1) \cdots p(x_N / y_N)}{p(\mathbf{x} / \mathbf{y})} \right]$$

$$= \log \left[\sum_{\mathbf{y}} p(\mathbf{y}) \left(\sum_{x_1} p(x_1 / y_1) \cdots \sum_{x_N} p(x_N / y_N) \right) \right] = \log 1 = 0$$

2.8 互信息量与信道输入符号相关性的关系



说明:

- (X_1, X_2, \dots, X_N) 作为一个噪声信道的输入
- (Y_1, Y_2, \dots, Y_N) 作为其输出
- 定理2.8说明: 如果输入是相互独立的, \mathbf{Y} 所提供的关于 \mathbf{X} 的信息量, 比每个 Y_i 所提供的关于相应 X_i 的信息量的总和要多.

2.8 互信息量与信道输入符号相关性的关系



例题：

- 设 X_1, X_2, \dots, X_n 是独立同分布的离散随机变量
它们的熵都为 H
- 设 π 是集合 $\{1, 2, \dots, n\}$ 的一个置换，并且令 $Y_i = X_{\pi(i)}$
- 则 $I(\mathbf{X}; \mathbf{Y}) = nH$
- 但 $\sum I(X_i; Y_i) = kH$
这里 k 是 π 中固定点的数目，即满足 $\pi(i) = i$ 的整数 i 的数目
- 特别是如果 π 没有固定点
例如 $\pi(i) \equiv i+1 \pmod{n}$ ，则 $\sum I(X_i; Y_i) = 0$

目录



- 熵的性质
- 互信息量的性质
- 条件熵及Fano不等式
- 复合观测的互信息量
- 数据处理定理
- 互信息量与信道输入概率分布的关系
- 互信息量与信道转移概率分布的关系
- 互信息量与信道输入符号相关性的关系
- 互信息量与信道记忆特性的关系

2.9 互信息量与信道记忆特性的关系



定理2.9：信道是离散无记忆的

$$\begin{aligned}\text{即 } p(\mathbf{y} / \mathbf{x}) &= p(y_1, y_2, \dots, y_N / x_1, x_2, \dots, x_N) \\ &= p(y_1 / x_1) p(y_2 / x_2) \cdots p(y_N / x_N) = \prod_{i=1}^N p(y_i / x_i)\end{aligned}$$

$$\text{则 } I(\mathbf{X}; \mathbf{Y}) \leq \sum_{i=1}^N I(X_i; Y_i)$$

2.9 互信息量与信道记忆特性的关系



例题：

- 设 X 是熵为 H 的随机变量
- 令 $X_1=X_2=\dots=X_n=Y_1=\dots=Y_n=X$
- 满足定理2.9的条件

有 $I(X; Y)=H$,

$$\sum I(X_i; Y_i)=nH$$

定理2.8和2.9的推论



推论：信道的输入和信道本身都是离散无记忆的，

$$\text{则 } I(\mathbf{X}; \mathbf{Y}) = \sum_{i=1}^N I(X_i; Y_i)$$

习题



2.1 证明定理2.4.

2.2 证明定理2.7.

2.3 证明定理2.9.

2.6 如果X, Y和Z是同一取值空间上的三个离散随机变量, 定义条件互信息量

$I(X; Y / Z)$ 为:

$$I(X; Y / Z) = \sum_{x, y, z} p(x, y, z) \log \frac{p(x, y / z)}{p(x / z) p(y / z)}$$

证明: (a) $I(X; Y / Z) = I(Y; X / Z)$

(b) $I(X; Y, Z) = I(X; Z) + I(X; Y / Z)$

(c) $I(X; Y / Z) \geq 0$, 当且仅当 (X, Z, Y) 是Markov链时等式成立.